

Diseño de un sistema de anonimización de voz en tiempo real para proteger la identidad vocal en telefonía móvil en Colombia

Alison Daiana Aristizabal Garcia^{1,2}

Asesores: Juan Fernando Pérez¹ y Yezid Donoso²

¹ Departamento de Ingeniería Industrial, Universidad de los Andes

² Departamento de Ingeniería de Sistemas y Computación, Universidad de los Andes

Abstract

Index Terms:

Resumen

Palabras clave:

1 Introducción

2 Marco teórico

2.1 Voz, identidad vocal y datos biométricos

La señal de voz transporta el contenido lingüístico (qué se dice) y rasgos fonéticos sobre cómo se dice. Entre ellos está la huella vocal (*voiceprint*), que permite distinguir a un hablante de otro (Deng et al., 2023). Por eso la literatura de privacidad de voz trata la voz como un dato biométrico y, en consecuencia, como información personalmente identificable (Patino et al., 2021). En Colombia, el tratamiento de estos datos se rige por la Ley 1581 de 2012 y el Decreto 1377 de 2013.

2.2 Anonimización y seudonimización de voz

Anonimizar voz consiste en manipular la señal para degradar la fiabilidad de los sistemas automáticos de reconocimiento de hablante, preservando aspectos como la inteligibilidad y la naturalidad (Patino et al., 2021). El VoicePrivacy Challenge exige que el sistema produzca una forma de onda, suprima la información del hablante y preserve la inteligibilidad, la naturalidad y la distintividad de la voz. Como cada hablante conserva una voz distinta pero anonimizada, Patino et al. (2021) señalan que la tarea se describe con más propiedad como seudonimización.

2.3 Verificación automática de locutor (ASV) y EER

Un sistema de verificación automática de locutor (ASV, *Automatic Speaker Verification*) decide si dos grabaciones pertenecen a la misma persona. Primero se inscribe (*enrollment*) con audios del hablante y luego evalúa nuevas grabaciones (*trials*) (Deng et al., 2023). Su desempeño se

resume con la *Equal Error Rate* (EER), el punto donde la tasa de falso rechazo iguala la de falsa aceptación. Aquí el ASV actúa como atacante, así que una EER más alta significa mejor privacidad.

2.4 Reconocimiento automático de habla (ASR) y WER

Un sistema ASR (*Automatic Speech Recognition*) transcribe el contenido de una grabación sin importar quién habla. La inteligibilidad se mide con la *Word Error Rate* (WER):

$$WER = \frac{N_{\text{sust}} + N_{\text{elim}} + N_{\text{ins}}}{N_{\text{ref}}} \quad (1)$$

donde N_{sust} , N_{elim} y N_{ins} son el número de sustituciones, eliminaciones e inserciones de palabras, y N_{ref} es el número de palabras de la transcripción de referencia (Deng et al., 2023). Una WER más baja significa mejor inteligibilidad.

2.5 Modelos de atacante

El VoicePrivacy distingue los modelos de atacante según su conocimiento del sistema (Patino et al., 2021; Tomashenko et al., 2024):

- El atacante *ignorante* no sabe que el audio fue anonimizado y lo compara contra grabaciones originales (escenario o-a).
- El atacante *semi-informado* conoce el sistema, pero no su configuración, y anonimiza los datos de inscripción con una configuración propia (escenario a-a). En el VPC2024 esto se hace a nivel de *utterance*.
- El atacante *informado* conoce el algoritmo y su configuración; Patino et al. (2021) no lo consideran.

- Quamer y Gutierrez-Osuna (2024) usan el término *lazy-informed* para el caso en que se anonimizan tanto los datos de inscripción como los de prueba, con hablantes objetivo distintos.

2.6 Modelo fuente-filtro y predicción lineal (LPC)

La predicción lineal (LPC, *Linear Predictive Coding*) modela el tracto vocal como un filtro todo-polo de orden p . Sus polos complejos se asocian a las resonancias del tracto (formantes), y el residuo de predicción (excitación) conserva la información de la fuente. El orden suele fijarse con la heurística de Markel y Gray (1976):

$$p = f_s + 4 \quad (2)$$

donde f_s es la frecuencia de muestreo expresada en kHz, lo que da $p = 20$ a 16 kHz.

2.7 Coeficiente de McAdams

Patino et al. (2021) transforman la envolvente espectral contrayendo o expandiendo la posición angular de los polos LPC con un coeficiente $\alpha < 1$. El efecto es un desplazamiento de formantes sin entrenamiento previo. La línea base original (B2) usa α fijo = 0.8, es determinista y fácilmente reversible. La versión estocástica sorteas $\alpha \in \mathcal{U}(\alpha_{\min}, \alpha_{\max})$, de modo que un adversario necesitaría conocer el valor exacto para revertir la transformación. Un $\alpha_{\min}$ más bajo mejora la anonimización a costa de la inteligibilidad. El método no logra anonimización perfecta: ninguna configuración alcanza la categoría ZEBRA «0» (Patino et al., 2021).

2.7.1. ZEBRA: evaluación de evidencia biométrica

ZEBRA (*Zero Evidence Biometric Recognition Assessment*) es un marco de evaluación que cuantifica la evidencia biométrica residual que un sistema de reconocimiento puede obtener a partir de una señal anonimizada. A diferencia de la EER, que resume el desempeño global de verificación, ZEBRA analiza cuánta evidencia permanece para relacionar una muestra con la identidad del hablante. La categoría «0» representa el nivel más favorable de privacidad dentro de este marco, aunque no implica anonimización absoluta ni irreversibilidad. En los experimentos de Patino et al. (2021), ninguna de las configuraciones basadas en el coeficiente de McAdams alcanza dicha categoría.

2.8 Tiempo real: latencia y factor de tiempo real

El factor de tiempo real (RTF, o RTC en Deng et al. (2023)) es la razón entre el tiempo de procesamiento y la duración del audio, y es adimensional. La latencia es el retardo entre la entrada y la salida: en Quamer y Gutierrez-Osuna (2024) es el tamaño del fragmento más el tiempo de cómputo, y el sistema es de tiempo real si la latencia es menor que el doble del fragmento. Para telefonía, la referencia habitual es la Recomendación ITU-T G.114, con un retardo unidireccional de hasta 150 ms.

3 Metodología

3.1 Criterios y alternativas

El método se eligió con cinco criterios: operar en tiempo real en CPU de un computador personal, no requerir entrenamiento con corpus grandes, ser alcanzable en un pregrado, contar con evidencia bajo métricas del VoicePrivacy y tener una implementación de referencia. Se compararon cuatro enfoques con la evidencia de sus propios artículos (Tabla 1).

Ninguno de los cuatro fue evaluado en español sobre telefonía, y ninguno midió resistencia a clonación de voz: solo miden contra sistemas ASV. Las cifras tampoco son comparables, porque cambian el atacante, el ASV, el ASR y el protocolo. Por ejemplo, el McAdams de Deng et al. (2023) obtiene una WER de 26.54 % con sus ASR, frente a 13.7 % en Patino et al. (2021).

3.2 Decisión

Se seleccionó el coeficiente de McAdams con α estocástico, sin componentes de aprendizaje profundo, por tres razones: no requiere entrenamiento, corre en CPU y tiene una implementación de referencia abierta (*baseline* B2 del VPC2024). El rango $\mathcal{U}(0.7, 0.9)$ es un punto de partida basado en Patino et al. (2021) y en Tayebi Arasteh et al. (2024), que usan $\mathcal{U}(0.75, 0.90)$. exploran cuatro rangos y muestran un compromiso entre privacidad e inteligibilidad. Por eso el rango de α será un factor del Diseño de Experimentos.

La decisión tiene costos que se declaran. Las conclusiones del VPC2024 indican que los métodos basados en conversión de voz superan a los de procesamiento de señal (Tomashenko et al., 2024). Quamer y Gutierrez-Osuna (2024) y Kuzmin et al. (2026) señalan además que las transformaciones globales no eliminan por completo los rasgos del hablante y ofrecen privacidad limitada. En contrapartida, ningún método neuronal revisado reúne a la vez ejecución en CPU, ausencia de entrenamiento y evidencia en español.

3.3 Datos, métricas y criterios

La evaluación usa Mozilla Common Voice Scripted Speech 26.0 en español (clips MP3 a 48 kHz, convertidos a WAV de 16 kHz). La privacidad se mide con la EER de un ASV preentrenado (ECAPA-TDNN), la inteligibilidad con la WER de un ASR en español preentrenado con datos originales (Whisper, como en el protocolo del VPC2024) y la eficiencia con el RTF.

Los criterios del proyecto son $EER > 30\%$, $WER < 15\%$ y $RTF < 0.1$. El primero corresponde a una de las cuatro condiciones de privacidad mínima del VPC2024 ($EER \geq 10, 20, 30$ y 40%) (Tomashenko et al., 2024). Los otros dos son criterios propios, sin umbral oficial. Los factores y niveles del Diseño de Experimentos quedan por definir.

Tabla 1: Alternativas evaluadas (cifras reportadas por cada artículo; no son comparables entre sí).

Enfoque	Entrenamiento / hardware	Tiempo real reportado	Privacidad y utilidad reportadas	Idioma evaluado
McAdams estocástico (Patino et al., 2021)	Ninguno	RTC 0.030 (medido por Deng et al. (2023), con $\alpha = 0.8$)	EER 33.8 % (semi-informado, $\mathcal{U}(0.7, 0.9)$); WER 13.7 % para $\mathcal{U}(0.8, 0.9)$	Inglés
Streaming <i>end-to-end</i> (Quamer & Gutierrez-Osuna, 2024)	LibriTTS, 2 GPU V100	Latencia de 230 ms (base) y 66 ms (lite) en CPU	EER a-a 39.2–42.0 %; WER 5.1–6.5 %	Inglés
Códec neuronal y modelo de lenguaje (Kuzmin et al., 2026)	8 GPU H100	180 ms y RTF 0.93 en GPU portátil; sin tiempo real en CPU	EER 46.5–47.7 % (<i>lazy-informed</i>) y 18.6–19.0 % (semi-informado); WER 4.7–6.6 %	Inglés
Ejemplos adversariales (Deng et al., 2023)	VoxCeleb1, 2 GPU RTX 3090	RTC 0.011	EER 46.10 % (ignorante); WER 7.65 %	Inglés (ASV); ASR en otros idiomas

3.4 Datos y ética

El proyecto no recolecta voces nuevas: usa un corpus público y, en las pruebas de captura en vivo, solo la voz de la autora.

4 Implementación

4.1 Arquitectura

4.2 Núcleo de procesamiento

El audio se divide en tramas de 20 ms con salto de 10 ms y ventana de Hann periódica, con reconstrucción por *overlap-add*. En cada trama se estiman los coeficientes LPC y sus polos, se aplica la transformación de McAdams a los polos complejos y se resintetiza con la excitación calculada con los coeficientes originales. La relación de ventana y salto es siempre 2:1 y se calcula dinámicamente según la frecuencia de muestreo. El orden LPC sigue la Ecuación (2), que da 20 a 16 kHz. El soporte de 8 kHz existe por diseño, pero no está validado de extremo a extremo.

4.3 Coeficiente α

El α se mantiene fijo durante toda una sesión y cambia entre sesiones. Se obtiene con el hash SHA-256 del identificador de sesión como semilla de un generador PCG64, con muestreo uniforme en $\mathcal{U}(0.7, 0.9)$. Se descartó fijarlo por contacto: permitiría a quien controla un número correlacionar llamadas sucesivas por su patrón de anonimización. También se descartó variarlo por fragmento, porque no reduce la superficie de ataque (el ASV no necesita conocer α) y un fragmento con α alto dejaría un punto débil de entrada. El par (coeficiente, semilla) no se registra en el uso normal; en la evaluación por lotes sí se guarda en un manifiesto, lo que es aceptable solo porque los datos son públicos.

4.4 Procesamiento en streaming

La clase `AnonymizerStream` procesa audio de forma incremental con dos *buffers* de estado: el audio crudo que no completa una trama y la cola de *overlap-add* pendiente. El método `flush()` cierra la sesión y libera el audio restante. La latencia algorítmica estimada es de unos 20 ms, sin incluir captura ni reproducción (estimación de diseño; la medición real está pendiente). Las pruebas confirman que procesar el audio de una vez o por fragmentos produce el mismo resultado.

4.5 Pipeline por lotes

Los clips MP3 de Common Voice se convierten a WAV de 16 kHz en un paso previo, con `soundfile` y `scipy.signal.resample_poly`. Esta conversión simula telefonía de banda ancha, no banda angosta ni efectos de códec. La función `anonymize_utterance` reutiliza el *stream* y recibe como identificador de sesión el nombre del clip, lo que hace reproducible el α de cada clip. Falta el bucle a nivel de corpus.

4.6 Validación del núcleo

El núcleo se validó por capas con pruebas de identidad: con el coeficiente forzado a 1.0, la salida debe reconstruir la entrada. Las pruebas recortan unos 10 ms en los extremos de cada *utterance*, donde la ventana atenúa el audio por falta de tramas vecinas.

4.7 Decisiones y desviaciones

La implementación de LPC usa autocorrelación con Levinson–Durbin (`scipy.linalg.solve_toeplitz`) en lugar del método de Burg de `librosa.lpc`. Se tomó porque `librosa` y `numba` no corren en el equipo de desarrollo (Windows con Smart App Control). Los coeficientes y polos resultantes no son idénticos a los de la referencia, así que

no se afirma paridad numérica con la *baseline* B2; el efecto sobre la EER y la WER no está cuantificado.

5 Resultados

Referencias

- Deng, J., Teng, F., Chen, Y., Chen, X., Wang, Z., & Xu, W. (2023). V-Cloak: Intelligibility-, naturalness- & timbre-preserving real-time voice anonymization. *32nd USENIX Security Symposium*, 5181-5198. <https://arxiv.org/abs/2210.15140>
- Kuzmin, N., Liu, S., Lee, K. A., & Chng, E. S. (2026). *Stream-Voice-Anon: Enhancing utility of real-time speaker anonymization via neural audio codec and language models*. arXiv: 2601.13948 [eess.AS]. <https://arxiv.org/abs/2601.13948>
- Markel, J. D., & Gray, A. H., Jr. (1976). *Linear Prediction of Speech*. Springer. <https://doi.org/10.1007/978-3-642-66286-7>
- Patino, J., Tomashenko, N., Todisco, M., Nautsch, A., & Evans, N. (2021). Speaker anonymisation using the McAdams coefficient. *Proceedings of Interspeech 2021*, 1099-1103. <https://doi.org/10.21437/Interspeech.2021-1070>
- Quamer, W., & Gutierrez-Osuna, R. (2024). End-to-end streaming model for low-latency speech anonymization. *2024 IEEE Spoken Language Technology Workshop (SLT)*, 727-734. <https://arxiv.org/abs/2406.09277>
- Tomashenko, N., Miao, X., Champion, P., Meyer, S., Wang, X., Vincent, E., Panariello, M., Evans, N., Yamagishi, J., & Todisco, M. (2024, 6 de septiembre). The VoicePrivacy 2024 Challenge. <https://www.voiceprivacychallenge.org>