Diseño de un sistema de anonimización de voz en tiempo real para proteger la identidad vocal en telefonía móvil en Colombia

Alison Daiana Aristizabal Garcia[1,2]
Asesores: Juan Fernando Pérez[1] y Yezid Donoso[2]

[1] Departamento de Ingeniería Industrial, Universidad de los Andes
[2] Departamento de Ingeniería de Sistemas y Computación, Universidad de los Andes

Abstract

Index Terms:

Resumen

Palabras clave:

1 Introducción

El fraude telefónico y el uso de técnicas de inteligencia artificial para suplantar la identidad de las personas representan un problema creciente de seguridad y privacidad. La voz, además de ser uno de los principales medios de comunicación, contiene características biométricas que permiten distinguir a un hablante y que pueden ser aprovechadas tanto por sistemas de reconocimiento como por tecnologías de síntesis y clonación. Barrington et al. [10] mostraron que las personas presentan dificultades para identificar de manera fiable voces generadas mediante inteligencia artificial, mientras que informes recientes sobre fraude describen el uso de clonación y suplantación vocal en esquemas de ingeniería social [11].

En Colombia, el problema se presenta en un contexto de alta exposición a llamadas no deseadas y potencialmente fraudulentas. Durante 2025 se reportaron más de 16.630 millones de llamadas spam [9], y TransUnion Colombia reportó que el 27 % de los intentos de fraude digital identificados en el país se realizaron mediante llamadas telefónicas [12]. En este escenario, cuando una persona responde una llamada de un número desconocido, fragmentos de su voz pueden quedar expuestos a un interlocutor potencialmente malicioso.

Las soluciones disponibles se concentran principalmente en identificar, clasificar o bloquear números sospechosos. Aunque estos mecanismos pueden reducir el contacto con llamadas no deseadas, no protegen directamente la señal vocal una vez que la conversación ha comenzado. Este vacío motiva el estudio de mecanismos preventivos capaces de actuar sobre la voz del usuario durante la comunicación.

El presente proyecto diseña y evalúa un sistema de anonimización de voz en tiempo real orientado a reducir la información biométrica asociada con la identidad del hablante, procurando preservar la inteligibilidad y mantener un costo computacional compatible con procesamiento en tiempo real. La propuesta se basa en una transformación estocástica mediante el coeficiente de McAdams, seleccionada por su bajo costo computacional, su posibilidad de ejecución en CPU y la ausencia de una etapa de entrenamiento con grandes corpus.

La pregunta de investigación que orienta el trabajo es: ¿en qué medida un sistema de anonimización de voz en tiempo real, activado ante llamadas de números desconocidos, protege la identidad vocal de usuarios de telefonía móvil en Colombia sin comprometer la inteligibilidad de la comunicación?

1.1 Justificación

El proyecto responde a un riesgo asociado con la exposición de la identidad vocal durante llamadas telefónicas. La elevada cantidad de llamadas spam y la participación de las llamadas dentro de los intentos de fraude digital en Colombia muestran un escenario de exposición relevante para los usuarios [9, 12]. Al mismo tiempo, la disponibilidad de tecnologías capaces de generar voces artificiales convincentes aumenta la importancia de proteger las características biométricas presentes en la señal de voz [10, 11].

El valor agregado del proyecto consiste en abordar el problema en el momento en que ocurre la exposición de la voz. En lugar de limitarse a identificar números potencialmente fraudulentos, se estudia la viabilidad de transformar la señal vocal antes de que llegue al interlocutor, reduciendo la información asociada con la identidad del hablante mientras se conserva el contenido lingüístico de la conversación. Esto plantea un problema de ingeniería en el que deben equilibrarse simultáneamente privacidad, inteligibilidad y desempeño computacional.

Además, el proyecto aporta evidencia experimental sobre

anonimización de voz en español. Gran parte de los trabajos comparados han sido evaluados principalmente en inglés o bajo escenarios distintos al considerado en este proyecto. El trabajo busca, por tanto, aportar evidencia sobre el comportamiento de una técnica de procesamiento de señal de bajo costo computacional en un contexto de interés para usuarios de telefonía móvil en Colombia.

2 Marco teórico

2.1 Voz, identidad vocal y datos biométricos

La señal de voz transporta el contenido lingüístico, es decir, qué se dice, y rasgos fonéticos asociados con cómo se dice. Entre ellos está la huella vocal (*voiceprint*), que permite distinguir a un hablante de otro [2]. Por esta razón, la literatura de privacidad de voz considera la señal vocal como una fuente de información biométrica y potencialmente identificable [1].

Las características biométricas presentes en la voz se relacionan con propiedades fisiológicas y conductuales del hablante. Entre ellas se encuentran la frecuencia fundamental, los formantes, el timbre, la prosodia, el ritmo del habla y diferentes características espectrales. La combinación de estos componentes permite que sistemas automáticos comparen grabaciones y estimen si pertenecen a una misma persona.

2.2 Anonimización y seudonimización de voz

Anonimizar voz consiste en modificar una señal de habla con el objetivo de reducir la capacidad de identificar al hablante, procurando conservar propiedades relevantes de la comunicación, como la inteligibilidad y la naturalidad [1]. El *VoicePrivacy Challenge* establece protocolos de evaluación en los que un sistema debe producir una nueva forma de onda, reducir la información asociada con el hablante y preservar la utilidad de la señal.

Como una voz transformada puede seguir siendo distinguible de otras voces sin corresponder directamente con la identidad original, Patino et al. [1] señalan que la tarea puede describirse con mayor precisión como seudonimización. En este trabajo se mantiene el término *anonimización* por consistencia con la literatura técnica del área.

2.3 Verificación automática de locutor (ASV) y EER

Un sistema de verificación automática de locutor (ASV, *Automatic Speaker Verification*) determina si dos grabaciones de voz pertenecen a la misma persona. El proceso incluye una etapa de inscripción (*enrollment*) y una etapa de evaluación mediante grabaciones de prueba (*trials*) [2].

Una de las métricas empleadas para evaluar un sistema ASV es la *Equal Error Rate* (EER), definida en el punto en que la tasa de falsas aceptaciones y la tasa de falsos rechazos son iguales:

$$\mathrm{FAR} = \mathrm{FRR}. \tag{1}$$

En este proyecto, el sistema ASV se interpreta como un atacante que intenta verificar la identidad original. Por lo tanto, una EER más alta representa una mayor dificultad para reconocer al hablante y, en consecuencia, un mejor resultado de privacidad bajo este modelo de evaluación.

2.4 Reconocimiento automático de habla (ASR) y WER

Un sistema ASR (*Automatic Speech Recognition*) transcribe el contenido lingüístico de una grabación independientemente de la identidad de quien habla. La inteligibilidad se evalúa mediante la *Word Error Rate* (WER):

$$\mathrm{WER} = \frac{N_{\mathrm{sust}} + N_{\mathrm{elim}} + N_{\mathrm{ins}}}{N_{\mathrm{ref}}}, \tag{2}$$

donde N_{sust}, N_{elim} y N_{ins} corresponden al número de sustituciones, eliminaciones e inserciones, respectivamente, y N_{ref} es el número de palabras en la transcripción de referencia [2]. Una WER menor indica una mejor preservación del contenido lingüístico.

2.5 Modelos de atacante

La evaluación de un sistema de anonimización depende del conocimiento que se supone que posee el adversario. El *VoicePrivacy Challenge* contempla diferentes escenarios de ataque [1, 4]:

- **Atacante ignorante:** no sabe que el audio fue anonimizado y compara las grabaciones anonimizadas contra grabaciones originales del hablante. Este escenario se representa como o–a.
- **Atacante semi-informado:** conoce el sistema de anonimización, pero no necesariamente la configuración exacta utilizada en las grabaciones de prueba. Anonimiza también los datos de inscripción y compara señales anonimizadas, en el escenario a–a.
- **Atacante informado:** conoce el algoritmo y su configuración. Patino et al. [1] no incluyen este escenario dentro de su evaluación principal.
- Quamer y Gutierrez-Osuna [3] emplean el término *lazy-informed* para un caso en el que inscripción y prueba son anonimizadas usando hablantes objetivo distintos.

2.6 Modelo fuente–filtro y predicción lineal (LPC)

La predicción lineal (LPC, *Linear Predictive Coding*) modela el tracto vocal mediante un filtro todo-polo de orden p. Sus polos complejos se asocian con resonancias del tracto vocal o formantes, mientras que el residuo de predicción conserva principalmente información asociada con la excitación. Una heurística comúnmente atribuida a Markel y Gray [6] define el orden como:

$$p = f_s + 4, \tag{3}$$

donde f_s es la frecuencia de muestreo expresada en kHz. Para una señal de 16 kHz, esta heurística produce $p = 20$.

2.7 Coeficiente de McAdams

Patino et al. [1] utilizan el coeficiente de McAdams para transformar la envolvente espectral mediante la modificación de la posición angular de los polos LPC. El efecto principal es un desplazamiento de los formantes sin requerir entrenamiento de un modelo.

Sea un polo complejo expresado como:

$$z_i = r_i e^{j\phi_i}, \tag{4}$$

donde r_i representa el radio y ϕ_i la posición angular. La transformación modifica el componente angular mediante un coeficiente α. La línea base B2 utiliza un valor fijo de $\alpha = 0.8$, mientras que una variante estocástica puede seleccionar el coeficiente dentro de un intervalo:

$$\alpha \in \mathcal{U}\left(\alpha_{\text{mín}}, \alpha_{\text{máx}}\right). \tag{5}$$

Cambiar el rango de α modifica el compromiso entre privacidad e inteligibilidad. Por esta razón, el intervalo utilizado se trata en este proyecto como un parámetro de diseño y no como un valor fijado de manera definitiva.

2.7.1 ZEBRA: evaluación de evidencia biométrica

ZEBRA (*Zero Evidence Biometric Recognition Assessment*) es un marco de evaluación que cuantifica la evidencia biométrica residual que un sistema de reconocimiento puede obtener a partir de una señal anonimizada. A diferencia de la EER, que resume el desempeño global de verificación, ZEBRA analiza cuánta evidencia permanece para relacionar una muestra con la identidad del hablante. La categoría "0" representa el nivel más favorable de privacidad dentro de este marco, aunque no implica anonimización absoluta ni irreversibilidad. En los experimentos de Patino et al. [1], ninguna de las configuraciones basadas en el coeficiente de McAdams alcanza dicha categoría.

3 Metodología

3.1 Criterios y restricciones de diseño

La selección del método se realizó considerando cinco criterios principales: operación en tiempo real sobre la CPU de un computador personal, ausencia de entrenamiento con corpus grandes, viabilidad dentro de un proyecto de pregrado, disponibilidad de evidencia bajo métricas de VoicePrivacy y existencia de una implementación de referencia.

Además, el diseño busca mantener independencia frente a los operadores móviles, por lo que el alcance experimental se concentra en el núcleo de procesamiento de voz y no en una integración directa con infraestructura celular comercial.

3.2 Comparación de alternativas

Se compararon cuatro enfoques de anonimización con base en los resultados reportados en sus respectivos trabajos. La Tabla 1 resume esta comparación.

Ninguno de los cuatro enfoques comparados fue evaluado específicamente en español sobre telefonía y ninguno de los trabajos incluidos en la comparación mide resistencia a clonación de voz; las evaluaciones se concentran en sistemas ASV. Además, las cifras no son directamente comparables debido a diferencias en los modelos de atacante, sistemas ASV y ASR, conjuntos de datos y protocolos de evaluación.

Las cifras presentadas en la Tabla 1 no son directamente comparables entre sí por tres razones principales. Primero, cambia el modelo de atacante utilizado en cada evaluación. La EER se reporta frente a un atacante ignorante en Deng et al. [2], frente a uno semi-informado en Patino et al. [1] y Kuzmin et al. [5], o bajo un escenario anonimizado–anonimizado (a–a) en Quamer y Gutierrez-Osuna [3]. Para un mismo sistema, el resultado puede variar considerablemente dependiendo de este supuesto. Por ejemplo, Kuzmin et al. [5] reportan una EER de 46.5–47.7 % frente a un atacante *lazy-informed*, pero de 18.6–19.0 % frente a uno semi-informado.

Segundo, también cambian los sistemas de verificación de locutor, los modelos ASR, los datos utilizados para su entrenamiento y los corpus de evaluación. Patino et al. [1] muestran que entrenar los modelos con audio anonimizado puede modificar de manera importante los resultados: para $\mathcal{U}(0.5, 0.9)$, la WER disminuye de aproximadamente 45 % a 9.6 % al utilizar un sistema adaptado al audio anonimizado. Asimismo, el método de McAdams obtiene una WER de 26.54 % cuando es evaluado con los sistemas ASR utilizados por Deng et al. [2], frente a 13.7 % en la configuración experimental de Patino et al. [1].

Tercero, el desempeño temporal se mide mediante definiciones y plataformas de hardware diferentes. Deng et al. [2] utilizan el cociente entre el tiempo de procesamiento y la duración del audio, denominado RTC; Quamer y Gutierrez-Osuna [3] reportan la latencia como la suma del tamaño del fragmento y el tiempo de cómputo sobre CPU; mientras que Kuzmin et al. [5] informan tanto latencia como RTF sobre una GPU portátil.

Por estas razones, la Tabla 1 se utiliza para contextualizar el orden de magnitud de los resultados y los requerimientos de cada enfoque como entrenamiento, hardware, idioma y capacidad de operación en tiempo real, y no para establecer una clasificación numérica directa entre métodos. Por la misma razón, los resultados obtenidos en este trabajo mediante ECAPA-TDNN, Whisper y Common Voice en español se analizan respecto a los criterios definidos para el proyecto y no se comparan numéricamente de forma directa con los valores reportados en estos artículos.

Tabla 1: Alternativas evaluadas. Las cifras corresponden a los valores reportados por cada trabajo y no son directamente comparables entre sí.

Enfoque	Entrenamiento / hardware	Tiempo real reportado	Privacidad y utilidad reportadas	Idioma evaluado
McAdams estocástico [1]	Ninguno	RTC 0.030, medido por Deng et al. [2] con $\alpha = 0.8$	EER 33.8 % en escenario semi-informado para $\mathcal{U}(0.7, 0.9)$; WER 13.7 % para $\mathcal{U}(0.8, 0.9)$	Inglés
Streaming *end-to-end* [3]	LibriTTS, 2 GPU V100	Latencia de 230 ms en versión base y 66 ms en versión *lite* sobre CPU	EER a–a de 39.2–42.0 %; WER de 5.1–6.5 %	Inglés
Códec neuronal y modelo de lenguaje [5]	8 GPU H100	180 ms y RTF 0.93 en GPU portátil; sin tiempo real en CPU	EER 46.5–47.7 % en *lazy-informed* y 18.6–19.0 % en semi-informado; WER 4.7–6.6 %	Inglés
Ejemplos adversariales [2]	VoxCeleb1, 2 GPU RTX 3090	RTC 0.011	EER 46.10 % en escenario ignorante; WER 7.65 %	Inglés para ASV

3.3 Selección del método

Se seleccionó el coeficiente de McAdams con α estocástico y sin componentes de aprendizaje profundo debido a que no requiere entrenamiento, puede ejecutarse sobre CPU y cuenta con una implementación de referencia dentro del ecosistema VoicePrivacy. El intervalo inicial $\mathcal{U}(0.7, 0.9)$ se toma como punto de partida a partir de los resultados de Patino et al. [1]. Tayebi Arasteh et al. [7] constituyen un antecedente adicional sobre el uso de intervalos similares y la evaluación de la técnica en voz en español.

El intervalo no se considera validado de antemano. Debido al compromiso entre privacidad e inteligibilidad observado en la literatura y en los resultados iniciales del proyecto, α se considera un parámetro de diseño que debe ser evaluado experimentalmente.

3.4 Datos y muestreo

La evaluación utiliza clips validados de Mozilla Common Voice 26.0 en español [8]. La muestra empleada contiene 6.700 grabaciones de 1.340 hablantes. El muestreo se realizó por estratos de acento autorreportado, con 134 hablantes por estrato. Los clips originales se convierten al formato requerido por el *pipeline* de procesamiento antes de la evaluación.

3.5 Métricas y criterios de evaluación

La privacidad se mide mediante la EER de un sistema ASV preentrenado basado en ECAPA-TDNN. La inteligibilidad se evalúa mediante la WER de Whisper utilizando el modelo *turbo*. La eficiencia computacional se evalúa mediante el RTF.

Los criterios definidos para el proyecto son:

- EER > 30 %;
- WER < 15 %;
- RTF < 0.1.

3.6 Diseño de Experimentos

3.7 Consideraciones éticas

El proyecto no recolecta nuevas voces para construir un corpus. La evaluación se realiza sobre un conjunto de datos público y, en las pruebas de captura en vivo, se utiliza únicamente la voz de la autora. El análisis de privacidad se limita a sistemas de verificación automática de locutor y no incluye pruebas de clonación de voz.

4 Implementación

4.1 Arquitectura

4.2 Núcleo de procesamiento

El audio se divide en tramas de 20 ms con un salto de 10 ms y una ventana de Hann periódica. La reconstrucción se realiza mediante *overlap-add*. En cada trama se estiman los coeficientes LPC y sus polos, se aplica la transformación de McAdams a los polos complejos y se resintetiza la señal utilizando la excitación calculada con los coeficientes originales.

La relación entre longitud de ventana y salto se mantiene en 2:1 y se calcula dinámicamente según la frecuencia de muestreo. El orden LPC sigue la Ecuación (3), que produce $p = 20$ a 16 kHz.

4.3 Generación del coeficiente α

4.4 Procesamiento en streaming

La clase `AnonymizerStream` procesa el audio de forma incremental y mantiene dos búferes de estado: el audio crudo que aún no completa una trama y la cola pendiente de *overlap-add*. El método `flush()` cierra la sesión y libera el audio restante.

La latencia algorítmica estimada es de aproximadamente 20 ms, sin incluir los tiempos de captura y reproducción. Este valor corresponde a una estimación de diseño; la medición completa de latencia permanece pendiente.

4.5 Pipeline por lotes

4.6 Validación del núcleo

El núcleo se validó por capas mediante pruebas de identidad. Cuando el coeficiente se fuerza a $\alpha = 1.0$, la salida debe reconstruir la señal de entrada. Las pruebas recortan aproximadamente 10 ms en los extremos de cada *utterance*, donde la ventana atenúa el audio por ausencia de tramas vecinas.

5 Resultados

6 Conclusiones

Referencias

[1] J. Patino, N. Tomashenko, M. Todisco, A. Nautsch, and N. Evans, "Speaker anonymisation using the McAdams coefficient," *Proceedings of Interspeech 2021*, pp. 1099–1103, 2021. doi: 10.21437/Interspeech.2021-1070.

[2] J. Deng, F. Teng, Y. Chen, X. Chen, Z. Wang, and W. Xu, "V-Cloak: Intelligibility-, naturalness- & timbre-preserving real-time voice anonymization," *32nd USENIX Security Symposium*, pp. 5181–5198, 2023. https://arxiv.org/abs/2210.15140

[3] W. Quamer and R. Gutierrez-Osuna, "End-to-end streaming model for low-latency speech anonymization," *2024 IEEE Spoken Language Technology Workshop (SLT)*, pp. 727–734, 2024. https://arxiv.org/abs/2406.09277

[4] N. Tomashenko et al., "The VoicePrivacy 2024 Challenge," 4th Symposium on Security and Privacy in Speech Communication, Kos, Greece, 2024. https://www.voiceprivacychallenge.org

[5] N. Kuzmin, S. Liu, K. A. Lee, and E. S. Chng, "StreamVoice-Anon: Enhancing utility of real-time speaker anonymization via neural audio codec and language models," *arXiv preprint arXiv:2601.13948*, 2026. https://arxiv.org/abs/2601.13948

[6] J. D. Markel and A. H. Gray Jr., *Linear Prediction of Speech*. Berlin, Heidelberg: Springer, 1976. doi: 10.1007/978-3-642-66286-7.

[7] S. Tayebi Arasteh et al., "Addressing challenges in speaker anonymization to maintain utility while ensuring privacy of pathological speech," *Communications Medicine*, vol. 4, Art. 182, 2024. doi: 10.1038/s43856-024-00609-5.

[8] R. Ardila, M. Branson, K. Davis, M. Kohler, J. Meyer, M. Henretty, R. Morais, L. Saunders, F. Tyers, and G. Weber, "Common Voice: A massively-multilingual speech corpus," *Proceedings of the Twelfth Language Resources and Evaluation Conference*, pp. 4218–4222, 2020. https://aclanthology.org/2020.lrec-1.520/

[9] ACIS, "Colombianos recibieron más de 16.630 millones de llamadas spam durante 2025," 9 de febrero de 2026. https://www.acis.org.co/blog/noticias-2/colombianos-recibieron-mas-de-16-630-millones-de-llamadas-spam-durante-2025-6036

[10] S. Barrington, E. A. Cooper, and H. Farid, "People are poorly equipped to detect AI-powered voice clones," *Scientific Reports*, vol. 15, Art. 11004, 2025. https://doi.org/10.1038/s41598-025-94170-3

[11] Group-IB, *The Voice of Fraud: Deepfake Vishing and the New Age of Social Engineering*, informe técnico, 2025. https://www.group-ib.com/resources/research-hub/voice-of-fraud/

[12] TransUnion Colombia, "27 % de los intentos de fraude digital en Colombia son a través de llamadas telefónicas," 22 de abril de 2025. https://noticias.transunion.co/27-de-los-intentos-de-fraude-digital-en-colombia-son-a-traves-de-llamadas-telefonicas/