Diseño de un sistema de anonimización de voz en tiempo real para proteger la identidad vocal en telefonía móvil en Colombia

Alison Daiana Aristizabal Garcia[1,2]
Asesores: Juan Fernando Pérez[1] y Yezid Donoso[2]

[1] Departamento de Ingeniería Industrial, Universidad de los Andes
[2] Departamento de Ingeniería de Sistemas y Computación, Universidad de los Andes

---

Abstract

Index Terms:

Resumen

Palabras clave:

---

1 Introducción

El fraude telefónico y el uso de técnicas de inteligencia artificial (IA) para suplantar la identidad de las personas son un problema creciente de seguridad y privacidad. La voz, además de ser uno de los principales medios de comunicación, contiene características biométricas que permiten distinguir a un hablante. Esas características pueden ser aprovechadas tanto por sistemas de reconocimiento como por tecnologías de síntesis y clonación de voz. Barrington et al. [10] mostraron que las personas no identifican de manera fiable las voces generadas con IA: en su estudio, los participantes juzgaron que una voz clonada pertenecía a la misma persona que la voz original alrededor del 80 % de las veces, y solo reconocieron como artificial cerca del 60 % de las voces clonadas. Informes recientes sobre fraude describen además el uso de la clonación de voz en esquemas de ingeniería social [11].

En Colombia, el problema ocurre en un contexto de alta exposición a llamadas no deseadas. Según datos de la aplicación Truecaller reseñados por ACIS, durante 2025 los colombianos recibieron más de 16 630 millones de llamadas spam [9]. En una encuesta de TransUnion Colombia a 995 personas, el 27 % de quienes afirmaron haber sido blanco de un intento de fraude digital entre agosto y diciembre de 2024 indicó que el intento ocurrió mediante *vishing* (*voice phishing*), es decir, una llamada en la que el estafador busca que la víctima entregue información personal; fue la modalidad más reportada [12]. En este escenario, cuando una persona contesta una llamada de un número desconocido, fragmentos de su voz quedan expuestos a un interlocutor potencialmente malicioso.

Las soluciones disponibles se concentran en identificar, clasificar o bloquear números sospechosos. Estos mecanismos reducen el contacto con llamadas no deseadas, pero no protegen la voz una vez que la conversación ha comenzado. Este vacío motiva el estudio de mecanismos preventivos que actúen sobre la voz del usuario durante la comunicación.

El presente proyecto diseña y evalúa un sistema de anonimización de voz en tiempo real. Anonimizar la voz significa transformarla para que sea más difícil reconocer quién habla, sin cambiar lo que se dice. La propuesta se basa en una transformación estocástica mediante el coeficiente de McAdams [1], seleccionada por tres razones: su bajo costo computacional, la posibilidad de ejecutarla en la unidad central de procesamiento (CPU, *Central Processing Unit*) de un computador personal sin una tarjeta gráfica, y la ausencia de una etapa de entrenamiento con grandes corpus de voz.

El sistema tiene dos componentes. El primero es un *pipeline* por lotes, que anonimiza un corpus completo de grabaciones y calcula las métricas de evaluación. El segundo es un prototipo de escritorio en tiempo real, que anonimiza la voz capturada por el micrófono mientras la persona habla. El alcance del proyecto llega hasta la anonimización de la voz en tiempo real.

Para evaluar el sistema se usan tres métricas, cada una asociada con una parte del problema. La privacidad se mide con la tasa de error igual (EER, *Equal Error Rate*) de un sistema de verificación automática de locutor (ASV, *Automatic Speaker Verification*), que actúa como un atacante que intenta reconocer al hablante. La inteligibilidad se mide con la tasa de error de palabras (WER, *Word Error Rate*) de un sistema de reconocimiento automático de habla (ASR, *Automatic Speech Recognition*), que comprueba si el contenido se sigue entendiendo. El tiempo real se mide con el factor de tiempo real (RTF, *Real-Time Factor*), que indica si el procesamiento es lo bastante rápido para una conversación. Estos conceptos se definen en detalle en la Sección 2.

La pregunta de investigación que orienta el trabajo es: ¿en qué medida un sistema de anonimización de voz en tiempo real, activado ante llamadas de números desconocidos, protege la identidad vocal de usuarios de telefonía móvil en Colombia sin comprometer la inteligibilidad de la comunicación?

1.1 Justificación

El proyecto responde a un riesgo asociado con la exposición de la identidad vocal durante llamadas telefónicas. La elevada cantidad de llamadas spam y la participación de las llamadas en los intentos de fraude digital en Colombia muestran un escenario de exposición relevante para los usuarios [9, 12]. Al mismo tiempo, la disponibilidad de tecnologías capaces de generar voces artificiales convincentes aumenta la importancia de proteger las características biométricas de la voz [10, 11].

El valor agregado del proyecto consiste en abordar el problema en el momento en que ocurre la exposición de la voz. En lugar de limitarse a identificar números potencialmente fraudulentos, se estudia la viabilidad de transformar la voz antes de que llegue al interlocutor, reduciendo la información asociada con la identidad del hablante y conservando el contenido de la conversación. Esto plantea un problema de ingeniería en el que deben equilibrarse a la vez la privacidad, la inteligibilidad y el desempeño computacional.

Además, el proyecto aporta evidencia experimental sobre anonimización de voz en español. Los trabajos comparados en la Sección 3 se evaluaron en inglés o en escenarios distintos al de este proyecto. Este trabajo aporta evidencia sobre el comportamiento de una técnica de procesamiento de señal de bajo costo computacional en un contexto de interés para usuarios de telefonía móvil en Colombia.

2 Marco teórico

2.1 Voz, identidad vocal y datos biométricos

La señal de voz transporta el contenido lingüístico, es decir, qué se dice, y rasgos asociados con cómo se dice. Entre ellos está la huella vocal (*voiceprint*), que permite distinguir a un hablante de otro [2]. Por esta razón, la literatura de privacidad de voz considera la voz una fuente de información biométrica que permite identificar a una persona [1].

Las características biométricas de la voz se relacionan con propiedades fisiológicas y de comportamiento del hablante, como la frecuencia fundamental, los formantes, el timbre, la prosodia y el ritmo del habla. La combinación de estos rasgos permite que un sistema automático compare dos grabaciones y estime si pertenecen a la misma persona.

Por esta razón, proteger la voz durante una llamada exige reducir esa información sin eliminar el mensaje, que es la tarea de la anonimización descrita en la Sección 2.2.

2.2 Anonimización y seudonimización de voz

Anonimizar voz consiste en modificar una señal de habla para reducir la capacidad de identificar al hablante, conservando propiedades relevantes de la comunicación, como la inteligibilidad y la naturalidad [1]. El *VoicePrivacy Challenge* (VPC) es una iniciativa internacional que define cómo evaluar estos sistemas: el sistema debe producir una nueva forma de onda, reducir la información del hablante y preservar la utilidad de la señal [4].

Como la voz transformada puede seguir siendo distinguible de otras voces sin corresponder a la identidad original, Patino et al. [1] señalan que la tarea se describe con más precisión como seudonimización. En este trabajo se usa el término anonimización por consistencia con la literatura técnica del área.

El efecto de una anonimización no se supone: se mide con la EER y la WER (Secciones 2.3 y 2.4), siguiendo los escenarios de ataque del VPC (Sección 2.5). Una anonimización exitosa en este sentido no garantiza que la identidad sea imposible de recuperar.

2.3 Verificación automática de locutor (ASV) y EER

Un sistema de verificación automática de locutor (ASV) decide si dos grabaciones pertenecen a la misma persona. El proceso tiene dos etapas. En la inscripción (*enrollment*), el sistema recibe grabaciones de un hablante y construye una representación de su voz. En la prueba (*trial*), recibe una grabación nueva, la compara con esa representación y obtiene una puntuación de similitud [2]. Si la puntuación supera un umbral, el sistema acepta que es la misma persona.

Con cualquier umbral, el sistema puede cometer dos errores. La tasa de falsa aceptación (FAR, *False Acceptance Rate*) es la proporción de comparaciones entre personas distintas que el sistema acepta como la misma persona. La tasa de falso rechazo (FRR, *False Rejection Rate*) es la proporción de comparaciones de una misma persona que el sistema rechaza. La EER es el valor en el que ambas tasas son iguales:

$$\mathrm{FAR}(\tau) = \mathrm{FRR}(\tau), \tag{1}$$

donde τ es el umbral de decisión. Una EER cercana a 0 % indica que el sistema reconoce bien a los hablantes; una EER cercana a 50 % indica que acierta como si decidiera al azar.

Cuando el ASV recibe grabaciones anonimizadas, cumple el papel de un atacante que intenta reconocer al hablante. Si la EER es alta, ese atacante se equivoca con frecuencia; por eso, al evaluar una anonimización, una EER más alta significa más privacidad. Para este fin se emplea el modelo preentrenado ECAPA-TDNN (*Emphasized Channel Attention, Propagation and Aggregation in Time Delay Neural Network*) [13], sin modificarlo.

2.4 Reconocimiento automático de habla (ASR) y WER

Un sistema de reconocimiento automático de habla (ASR) transcribe el contenido de una grabación, sin importar quién habla. La inteligibilidad se evalúa con la tasa de error de palabras (WER):

$$\mathrm{WER} = \frac{N_{\mathrm{sust}} + N_{\mathrm{elim}} + N_{\mathrm{ins}}}{N_{\mathrm{ref}}}, \tag{2}$$

donde N_{sust}, N_{elim} y N_{ins} son el número de palabras sustituidas, eliminadas e insertadas respecto a la transcripción de referencia, y N_{ref} es el número de palabras de esa referencia [2]. Una WER más baja indica que el contenido se conserva mejor. Como las inserciones también cuentan como errores, la WER puede superar el 100 % cuando el ASR agrega muchas palabras que no se dijeron.

Al comparar la WER de las grabaciones originales con la de las anonimizadas se puede saber si el mensaje se sigue entendiendo: si la WER aumenta poco, la anonimización conservó el contenido. Para transcribir se emplea el modelo preentrenado Whisper, versión *turbo*, basado en el trabajo de Radford et al. [14], sin modificarlo.

2.5 Modelos de atacante

El resultado de una evaluación de anonimización depende de lo que se supone que sabe el atacante. El VPC contempla varios escenarios [1, 4]. Cada uno se nombra con dos letras: la primera indica cómo están las grabaciones de inscripción y la segunda cómo están las de prueba, con "o" para original y "a" para anonimizada.

- **Atacante ignorante (o–a, original–anonimizado):** no sabe que el audio fue anonimizado. Inscribe al hablante con grabaciones originales y las compara con grabaciones anonimizadas.
- **Atacante semi-informado (a–a, anonimizado–anonimizado):** conoce el sistema de anonimización, pero no la configuración exacta usada en las grabaciones de prueba. Anonimiza también sus grabaciones de inscripción y compara audio anonimizado con audio anonimizado.
- **Atacante informado:** conoce el algoritmo y su configuración. Patino et al. [1] no incluyen este escenario en su evaluación principal.

Quamer y Gutierrez-Osuna [3] usan además el término *lazy-informed* para el caso en que la inscripción y la prueba se anonimizan con hablantes objetivo distintos.

A estos escenarios se suma el o–o (original–original), sin anonimización, que sirve de referencia: indica qué tan bien reconoce el ASV a los hablantes sin protección. En el contexto de una llamada, el escenario o–a representa a un atacante que graba la conversación y la compara con grabaciones reales de la víctima, y el a–a a un atacante que conoce el sistema y lo usa para anonimizar sus propias grabaciones de la víctima.

2.6 Modelo fuente–filtro y predicción lineal (LPC)

El modelo fuente–filtro describe cómo se produce la voz. Se puede comparar con una trompeta: el músico hace vibrar los labios contra la boquilla y produce un zumbido, y el tubo de metal transforma ese zumbido en el sonido de la trompeta. En la voz, la fuente es el sonido que se produce en la garganta y el filtro es el tracto vocal, formado por la garganta, la boca y la nariz. Este modelo separa la voz en dos componentes: la excitación, que corresponde a la fuente, y los formantes, que dependen de la forma del filtro.

2.6.1 Excitación

La excitación es el sonido que produce la fuente antes de pasar por el tracto vocal. En los sonidos sonoros, como las vocales, proviene de la vibración de las cuerdas vocales; en los sonidos sordos, como la "s" o la "f", proviene del paso turbulento del aire. La excitación lleva la frecuencia fundamental, es decir, qué tan grave o aguda suena la voz, y el ritmo y la entonación del habla.

Si la excitación se conserva sin cambios, se conservan también el ritmo y la entonación con los que se dice el mensaje, lo que ayuda a que siga siendo comprensible. Esto implica también que la frecuencia fundamental del hablante no cambia.

2.6.2 Formantes

Al pasar por el tracto vocal, la excitación se transforma: el tubo refuerza algunas frecuencias y atenúa otras. Las zonas de frecuencia reforzadas se llaman formantes. Su posición depende de la forma y el tamaño del tracto vocal. Por eso, los formantes cambian con cada sonido que se pronuncia, ya que la boca toma una forma distinta en cada vocal, y también varían de una persona a otra, porque cada persona tiene un tracto vocal diferente. Esta segunda propiedad hace que los formantes contribuyan a que cada voz suene distinta.

Por esta razón, desplazar los formantes hace que la voz deje de sonar como el tracto vocal del hablante original.

2.6.3 Predicción lineal (LPC)

Para modificar los formantes sin tocar la excitación, primero hay que separarlos. La predicción lineal (LPC, *Linear Predictive Coding*) es la técnica matemática que hace esa separación a partir de una grabación.

La idea de la LPC es que cada muestra de una señal de voz se puede predecir bastante bien como una combinación de las p muestras anteriores:

$$\hat{s}[n] = a_1 s[n-1] + a_2 s[n-2] + \cdots + a_p s[n-p].$$

Los pesos $a_1, \ldots, a_p$ se llaman coeficientes LPC y se eligen para que el error de predicción sea el menor posible. Esos coeficientes describen el filtro, es decir, la forma del tracto vocal. Lo que la predicción no logra explicar, el error $s[n] - \hat{s}[n]$, se llama residuo de predicción y corresponde a la excitación.

En términos técnicos, la LPC representa el tracto vocal como un filtro todo-polo de orden p. Los polos son las raíces del polinomio que forman los coeficientes. Los polos complejos aparecen en pares, y cada par cercano al círculo unitario corresponde a un formante: el ángulo del polo indica la frecuencia del formante y el radio indica qué tan marcado es. Por esta relación, mover el ángulo de los polos equivale a mover los formantes.

Como la forma de la boca cambia todo el tiempo al hablar, la LPC no se calcula una sola vez sobre toda la grabación, sino sobre fragmentos cortos de audio, llamados tramas, en los que el tracto vocal casi no cambia. El orden p fija cuántos coeficientes describen el filtro. Una heurística comúnmente atribuida a Markel y Gray [6] define el orden como:

$$p = f_s + 4, \tag{3}$$

donde f_s es la frecuencia de muestreo expresada en kHz. Para una señal de 16 kHz, esta heurística produce $p = 20$.

El orden p es el número de coeficientes, y por tanto de polos, del filtro. Como cada formante necesita un par de polos y en el habla aparece aproximadamente un formante por cada kHz del rango de frecuencias de la señal (hasta $f_s/2$), se requieren f_s polos para los formantes, más 4 para la forma general del espectro de la fuente: a 16 kHz, $p = 20$. Elegir bien p es importante. Si es muy pequeño, algunos formantes quedan sin representar y se mezclan con la excitación; si es muy grande, el filtro describe detalles que no son formantes, como los armónicos de la voz. En ambos casos, la separación entre formantes y excitación deja de ser correcta.

Al calcular la LPC en cada trama, con el orden p de la Ecuación (3), se obtienen por separado el filtro, representado por sus polos, y la excitación. Si se modifica solo el ángulo de los polos y luego se pasa la excitación original por el filtro modificado, los formantes se desplazan: cambian los rasgos del tracto vocal del hablante y se conserva lo que se dice. La Sección 2.7 explica cómo se modifican los polos.

2.7 Coeficiente de McAdams

Patino et al. [1] usan el coeficiente de McAdams para transformar la envolvente espectral modificando la posición angular de los polos LPC. El efecto principal es un desplazamiento de los formantes, sin necesidad de entrenar un modelo.

Un polo complejo se expresa como:

$$z_i = r_i \, e^{j\phi_i}, \tag{4}$$

donde r_i es el radio y ϕ_i la posición angular, medida en radianes entre 0 y π. El ángulo indica la frecuencia del formante asociado al polo: $f_i = \phi_i f_s/(2\pi)$.

La transformación de McAdams eleva el ángulo de cada polo complejo a la potencia α y deja su radio sin cambios:

$$z_i' = r_i \, e^{j\phi_i^{\alpha}}, \tag{5}$$

El procedimiento en cada trama es el siguiente [1]:

1. Se calcula la LPC de la trama y se obtienen sus coeficientes y su excitación.
2. Se convierten los coeficientes en polos.
3. A cada polo complejo con ángulo positivo se le cambia el ángulo ϕ_i por ϕ_i^{α}, conservando el radio r_i. Su polo conjugado recibe el mismo cambio en sentido opuesto, de modo que el par sigue siendo conjugado. Los polos reales, que no corresponden a formantes, no se modifican.
4. Los polos transformados se convierten de nuevo en coeficientes LPC.
5. Se reconstruye la trama pasando la excitación original por el filtro con los nuevos coeficientes.

Como los ángulos están entre 0 y π, elevarlos a una potencia $\alpha < 1$ no los desplaza a todos en la misma dirección. Los ángulos menores que 1 radián aumentan y los mayores que 1 radián disminuyen; el ángulo de 1 radián no cambia. A 16 kHz, 1 radián corresponde a unos 2.5 kHz [1]. Por eso, con $\alpha < 1$, los formantes por debajo de 2.5 kHz suben de frecuencia y los que están por encima bajan, y el espectro se contrae hacia esa frecuencia. Por ejemplo, con $\alpha = 0.8$ y $f_s = 16$ kHz, un formante en 700 Hz ($\phi = 0.275$ rad) pasa a unos 906 Hz ($\phi^{\alpha} = 0.356$ rad), y uno en 3300 Hz ($\phi = 1.296$ rad) pasa a unos 3134 Hz ($\phi^{\alpha} = 1.231$ rad). Cuanto más lejos de 1 está α, mayor es el desplazamiento de los formantes.

La línea base B2 del VPC usa un valor fijo $\alpha = 0.8$. La variante estocástica, en cambio, sortea el coeficiente de una distribución uniforme dentro de un intervalo:

$$\alpha \sim \mathcal{U}(\alpha_{\text{mín}}, \alpha_{\text{máx}}), \tag{6}$$

donde $\mathcal{U}(a, b)$ indica que cualquier valor entre a y b tiene la misma probabilidad de ser elegido. Cambiar el intervalo de α modifica el compromiso entre privacidad e inteligibilidad [1].

En el sistema propuesto, α se sortea una vez por llamada y se mantiene fijo durante toda la llamada; en la evaluación sobre un corpus de grabaciones, se sortea un α por grabación. Como el intervalo determina el equilibrio entre privacidad e inteligibilidad, se trata como un parámetro de diseño que se evalúa experimentalmente, no como un valor fijado de antemano.

2.7.1 ZEBRA: evaluación de evidencia biométrica

ZEBRA (*Zero Evidence Biometric Recognition Assessment*) es un marco de evaluación que mide cuánta evidencia sobre la identidad del hablante permanece en las grabaciones anonimizadas, y la resume en categorías. La categoría "0" corresponde a evidencia nula, es decir, a privacidad perfecta. Patino et al. [1] reportan que ninguna configuración basada en el coeficiente de McAdams alcanza esa categoría.

Aunque ZEBRA no se calcula en este trabajo, el resultado de Patino et al. [1] deja claro que el coeficiente de McAdams reduce la información del hablante, pero no logra una anonimización perfecta.

2.8 Tiempo real: latencia y factor de tiempo real (RTF)

El factor de tiempo real (RTF) es la razón entre el tiempo que tarda el sistema en procesar un audio y la duración de ese audio:

$$\mathrm{RTF} = \frac{T_{\text{procesamiento}}}{T_{\text{audio}}}. \tag{7}$$

Un RTF menor que 1 indica que el sistema procesa más rápido de lo que dura el audio. Por ejemplo, un RTF de 0.1 significa que procesar 10 s de voz toma 1 s. Deng et al. [2] usan la misma definición con el nombre de coeficiente de tiempo real (RTC, *Real-Time Coefficient*). La latencia es el retardo entre el momento en que se habla y el momento en que sale la voz transformada; Quamer y Gutierrez-Osuna [3] la calculan como el tamaño del fragmento de audio más el tiempo de cómputo.

Por eso, el RTF del núcleo de anonimización permite comprobar si el procesamiento es lo bastante rápido para una conversación. La latencia algorítmica, por su parte, depende del tamaño de los fragmentos de audio que se procesan (Sección 4.4).

3 Metodología

La metodología sigue tres etapas, una por cada objetivo específico. Primero, se comparan técnicas de anonimización y se selecciona una con criterios explícitos (Secciones 3.1 a 3.3). Segundo, se implementa la técnica seleccionada en un núcleo de procesamiento común a un *pipeline* por lotes y a un prototipo en tiempo real (Sección 4). Tercero, se evalúa el sistema sobre un corpus público en español con las métricas EER, WER y RTF (Secciones 3.4 a 3.6).

3.1 Criterios y restricciones de diseño

El método se seleccionó con cinco criterios, cada uno ligado a una restricción del proyecto:

- Operación en tiempo real en la CPU de un computador personal, porque el sistema debe procesar la voz durante la conversación sin hardware especializado.
- Ausencia de entrenamiento con corpus grandes, porque entrenar un modelo de voz exige datos y unidades de procesamiento gráfico (GPU, *Graphics Processing Unit*) fuera del alcance de un proyecto de pregrado.
- Viabilidad dentro de un proyecto de pregrado, en tiempo y recursos.
- Evidencia bajo las métricas del VPC, para poder comparar el comportamiento esperado con resultados publicados.
- Existencia de una implementación de referencia, para verificar la propia implementación.

Además, el diseño busca independencia frente a los operadores móviles. Por eso el alcance experimental se concentra en el núcleo de procesamiento de voz y no en una integración con la infraestructura celular comercial.

3.2 Comparación de alternativas

Se compararon cuatro enfoques de anonimización con base en los resultados reportados en sus propios artículos. La Tabla 1 resume esta comparación. Ninguno de los cuatro fue evaluado en español ni sobre audio de telefonía, y ninguno mide resistencia a la clonación de voz: todos evalúan su protección frente a sistemas ASV.

Las cifras de la Tabla 1 no son comparables entre sí por tres razones. Primero, cambia el modelo de atacante. La EER se reporta frente a un atacante ignorante en Deng et al. [2], frente a uno semi-informado en Patino et al. [1] y Kuzmin et al. [5], y en el escenario a–a en Quamer y Gutierrez-Osuna [3]. Para un mismo sistema, el resultado cambia mucho según este supuesto: Kuzmin et al. [5] reportan una EER de 46.5–47.7 % frente a un atacante *lazy-informed* y de 18.6–19.0 % frente a uno semi-informado.

Segundo, cambian los sistemas ASV y ASR, sus datos de entrenamiento y los corpus de evaluación. Patino et al. [1] muestran que reentrenar los modelos con audio anonimizado modifica de forma importante los resultados: para $\mathcal{U}(0.5, 0.9)$, la WER baja de 45 % a 9.6 %. Además, el método de McAdams obtiene una WER de 26.54 % con los ASR de Deng et al. [2], frente a 13.7 % en la configuración de Patino et al. [1].

Tercero, el desempeño temporal se mide con definiciones y hardware distintos. Deng et al. [2] reportan el RTC; Quamer y Gutierrez-Osuna [3] reportan la latencia como el tamaño del fragmento más el tiempo de cómputo en CPU; y Kuzmin et al. [5] reportan la latencia y el RTF en una GPU portátil.

Por estas razones, la Tabla 1 se usa para ubicar el orden de magnitud de los resultados y los requisitos de cada enfoque (entrenamiento, hardware, idioma y operación en tiempo real), y no para clasificar los métodos numéricamente. Por la misma razón, los resultados de este trabajo, obtenidos con ECAPA-TDNN, Whisper y Common Voice en español, se analizan frente a los criterios del proyecto y no se comparan numéricamente con los de estos artículos.

3.3 Selección del método

Se seleccionó el coeficiente de McAdams con α estocástico, sin componentes de aprendizaje profundo, porque cumple los cinco criterios de la Sección 3.1: no requiere entrenamiento, se ejecuta en CPU y cuenta con una implementación de referencia en el ecosistema del VPC. El intervalo inicial $\mathcal{U}(0.7, 0.9)$ se toma como punto de partida a partir de Patino et al. [1], que exploran varios intervalos y muestran un compromiso entre privacidad e inteligibilidad.

Tabla 1: Alternativas evaluadas. Las cifras corresponden a los valores reportados por cada trabajo y no son comparables entre sí.

Enfoque	Entrenamiento / hardware	Tiempo real reportado	Privacidad y utilidad reportadas	Idioma evaluado
McAdams estocástico [1]	Ninguno	RTC 0.030, medido por Deng et al. [2] con $\alpha = 0.8$	EER 33.8 % en escenario semi-informado para $\mathcal{U}(0.7, 0.9)$; WER 13.7 % para $\mathcal{U}(0.8, 0.9)$	Inglés
Streaming *end-to-end* [3]	LibriTTS, 2 GPU V100	Latencia de 230 ms en versión base y 66 ms en versión *lite* sobre CPU	EER a–a de 39.2–42.0 %; WER de 5.1–6.5 %	Inglés
Códec neuronal y modelo de lenguaje [5]	8 GPU H100	180 ms y RTF 0.93 en GPU portátil; sin tiempo real en CPU	EER 46.5–47.7 % en *lazy-informed* y 18.6–19.0 % en semi-informado; WER 4.7–6.6 %	Inglés
Ejemplos adversariales [2]	VoxCeleb1, 2 GPU RTX 3090	RTC 0.011	EER 46.10 % en escenario ignorante; WER 7.65 %	ASV: inglés y chino. ASR: inglés, chino, francés e italiano

Como antecedente en español, Tayebi Arasteh et al. [7] aplicaron el coeficiente de McAdams aleatorizado a habla patológica de más de 2 700 hablantes de instituciones alemanas y, en un análisis complementario, al corpus PC-GITA en español, con pacientes con enfermedad de Parkinson y controles sanos. Es evidencia de que la técnica se ha aplicado a voz en español, pero no a conversaciones telefónicas.

El intervalo no se considera validado de antemano. Por el compromiso entre privacidad e inteligibilidad observado en la literatura, α se trata como un parámetro de diseño que se evalúa experimentalmente (Sección 3.6).

3.4 Datos y muestreo

La evaluación usa clips validados de Mozilla Common Voice 26.0 en español [8], es decir, grabaciones que la comunidad del proyecto revisó y aceptó. La muestra contiene 6 700 grabaciones de 1 340 hablantes, con cinco grabaciones por hablante: tres para la inscripción del ASV y dos de prueba.

El muestreo se hizo por estratos de acento autorreportado, con 134 hablantes por estrato. El objetivo es que todos los grupos de acento tengan el mismo peso y que los resultados no dependan del acento más frecuente en el corpus; 134 es el número de hablantes elegibles del estrato más pequeño. Common Voice no tiene una categoría de acento colombiano: las voces colombianas quedan dentro de categorías regionales más amplias, como “andino-pacífico” y “caribe”.

Los clips originales, en formato MP3 a 48 kHz, se convierten a formato WAV (*Waveform Audio File Format*) a 16 kHz antes de la evaluación. Esta conversión representa telefonía de banda ancha y no simula la banda angosta de 8 kHz ni los efectos de los códecs telefónicos.

3.5 Métricas y criterios de evaluación

Cada métrica responde a una parte de la pregunta de investigación. La Tabla 2 resume qué mide cada una, cómo se obtiene, para qué se usa y cuál es el criterio del proyecto.

Los tres criterios son metas del proyecto. Una configuración cumple el objetivo del proyecto solo si satisface los tres a la vez.

3.6 Diseño de Experimentos

3.7 Consideraciones éticas

El proyecto no recolecta voces nuevas para construir un corpus. La evaluación se realiza sobre un conjunto de datos público y, en las pruebas de captura en vivo, se usa únicamente la voz de la autora. El análisis de privacidad se limita a sistemas de verificación automática de locutor y no incluye pruebas de clonación de voz.

4 Implementación

4.1 Arquitectura

4.2 Núcleo de procesamiento

El audio se divide en tramas, es decir, fragmentos cortos de 20 ms que se toman cada 10 ms, de modo que cada trama se solapa a la mitad con la siguiente. A cada trama se le aplica una ventana de Hann periódica, que suaviza sus bordes. En cada trama se estiman los coeficientes LPC y sus polos, se aplica la transformación de McAdams a los polos complejos y se reconstruye la señal con la excitación calculada con los coeficientes originales. Finalmente, las tramas se vuelven a unir sumando sus partes solapadas, un método llamado *overlap-add*.

La relación entre la longitud de la trama y el salto se mantiene en 2:1 y se calcula según la frecuencia de muestreo.

Tabla 2: Métricas de evaluación del proyecto.

Métrica	Qué mide	Cómo se obtiene	Para qué se usa	Criterio
EER (privacidad)	Qué tan bien reconoce un atacante al hablante después de anonimizar	ASV ECAPA-TDNN preentrenado, en los escenarios o–o, o–a y a–a	Determinar si la anonimización protege la identidad vocal	EER > 30 %
WER (inteligibilidad)	Cuánto contenido se pierde al anonimizar	ASR Whisper *turbo* preentrenado, sobre las grabaciones originales y anonimizadas	Determinar si la conversación se sigue entendiendo	WER < 15 %
RTF (tiempo real)	Cuánto tarda el procesamiento frente a la duración del audio	Tiempo de procesamiento del núcleo dividido por la duración del audio	Determinar si el sistema puede operar durante una llamada	RTF < 0.1

El orden LPC sigue la Ecuación (3), que produce $p = 20$ a 16 kHz.

4.3 Generación del coeficiente α

4.4 Procesamiento en streaming

La clase `AnonymizerStream` procesa el audio de forma incremental, a medida que llega, en lugar de esperar la grabación completa. Para eso mantiene dos búferes, es decir, espacios de memoria temporal: uno con el audio que todavía no completa una trama y otro con la parte de la reconstrucción *overlap-add* que aún no se puede entregar. El método `flush()` cierra la sesión al terminar la llamada y entrega el audio restante.

La latencia algorítmica estimada es de aproximadamente 20 ms, sin incluir los tiempos de captura y reproducción. Este valor es una estimación de diseño; la medición completa de la latencia está pendiente.

4.5 Pipeline por lotes

4.6 Validación del núcleo

El núcleo se validó por capas mediante pruebas de identidad. Cuando el coeficiente se fuerza a $\alpha = 1.0$, la transformación no modifica los polos y la salida debe reconstruir la señal de entrada. Las pruebas descartan aproximadamente 10 ms en cada extremo de cada enunciado (*utterance*, una grabación de una frase), donde la ventana atenúa el audio porque no hay tramas vecinas que completen la suma.

5 Resultados

6 Conclusiones

Tabla de acrónimos

Referencias

[1] J. Patino, N. Tomashenko, M. Todisco, A. Nautsch, and N. Evans, "Speaker anonymisation using the McAdams coefficient," *Proceedings of Interspeech 2021*, pp. 1099–1103, 2021. doi: 10.21437/Interspeech.2021-1070.

[2] J. Deng, F. Teng, Y. Chen, X. Chen, Z. Wang, and W. Xu, "V-Cloak: Intelligibility-, naturalness- & timbre-preserving real-time voice anonymization," *32nd USENIX Security Symposium*, pp. 5181–5198, 2023. https://arxiv.org/abs/2210.15140

[3] W. Quamer and R. Gutierrez-Osuna, "End-to-end streaming model for low-latency speech anonymization," *2024 IEEE Spoken Language Technology Workshop (SLT)*, pp. 727–734, 2024. https://arxiv.org/abs/2406.09277

[4] N. Tomashenko et al., "The VoicePrivacy 2024 Challenge," *4th Symposium on Security and Privacy in Speech Communication*, Kos, Greece, 2024. https://www.voiceprivacychallenge.org

[5] N. Kuzmin, S. Liu, K. A. Lee, and E. S. Chng, "StreamVoice-Anon: Enhancing utility of real-time speaker anonymization via neural audio codec and language models," *arXiv preprint arXiv:2601.13948*, 2026. https://arxiv.org/abs/2601.13948

[6] J. D. Markel and A. H. Gray Jr., *Linear Prediction of Speech*. Berlin, Heidelberg: Springer, 1976. doi: 10.1007/978-3-642-66286-7.

[7] S. Tayebi Arasteh, T. Arias-Vergara, P. A. Pérez-Toro, T. Weise, K. Packhäuser, M. Schuster, E. Nöth, A. Maier, and S. H. Yang, "Addressing challenges in speaker anonymization to maintain utility while ensuring privacy of pathological speech," *Communications Medicine*, vol. 4, Art. 182, 2024. doi: 10.1038/s43856-024-00609-5.

[8] R. Ardila, M. Branson, K. Davis, M. Kohler, J. Meyer, M. Henretty, R. Morais, L. Saunders, F. Tyers, and G. Weber, "Common Voice: A massively-multilingual speech corpus," *Proceedings of the Twelfth Language Resources and Evaluation Conference*, pp. 4218–4222, 2020. https://aclanthology.org/2020.lrec-1.520/

Acrónimo	Significado
a–a, o–a, o–o	Escenarios de evaluación: anonimizado–anonimizado, original–anonimizado, original–original
ASR	Reconocimiento automático de habla (*Automatic Speech Recognition*)
ASV	Verificación automática de locutor (*Automatic Speaker Verification*)
CPU	Unidad central de procesamiento (*Central Processing Unit*)
ECAPA-TDNN	*Emphasized Channel Attention, Propagation and Aggregation in Time Delay Neural Network*
EER	Tasa de error igual (*Equal Error Rate*)
FAR	Tasa de falsa aceptación (*False Acceptance Rate*)
FRR	Tasa de falso rechazo (*False Rejection Rate*)
GPU	Unidad de procesamiento gráfico (*Graphics Processing Unit*)
IA	Inteligencia artificial
LPC	Predicción lineal (*Linear Predictive Coding*)
RTC	Coeficiente de tiempo real (*Real-Time Coefficient*)
RTF	Factor de tiempo real (*Real-Time Factor*)
VPC	*VoicePrivacy Challenge*
WAV	*Waveform Audio File Format*
WER	Tasa de error de palabras (*Word Error Rate*)
ZEBRA	*Zero Evidence Biometric Recognition Assessment*

[9] ACIS, "Colombianos recibieron más de 16.630 millones de llamadas spam durante 2025," 9 de febrero de 2026. https://www.acis.org.co/blog/noticias-2/colombianos-recibieron-mas-de-16-630-millones-de-llamadas-spam-durante-2025-6036

[10] S. Barrington, E. A. Cooper, and H. Farid, "People are poorly equipped to detect AI-powered voice clones," *Scientific Reports*, vol. 15, Art. 11004, 2025. https://doi.org/10.1038/s41598-025-94170-3

[11] Group-IB, *The Voice of Fraud: Deepfake Vishing and the New Age of Social Engineering*, informe técnico, 2025. https://www.group-ib.com/resources/research-hub/voice-of-fraud/

[12] TransUnion Colombia, "27 % de los intentos de fraude digital en Colombia son a través de llamadas telefónicas," 22 de abril de 2025. https://noticias.transunion.co/27-de-los-intentos-de-fraude-digital-en-colombia-son-a-traves-de-llamadas-telefonicas/

[13] B. Desplanques, J. Thienpondt, and K. Demuynck, "ECAPA-TDNN: Emphasized channel attention, propagation and aggregation in TDNN based speaker verification," *Proceedings of Interspeech 2020*, pp. 3830–3834, 2020. doi: 10.21437/Interspeech.2020-2650.

[14] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust speech recognition via large-scale weak supervision," *Proceedings of the 40th International Conference on Machine Learning*, PMLR, vol. 202, pp. 28492–28518, 2023. https://proceedings.mlr.press/v202/radford23a.html